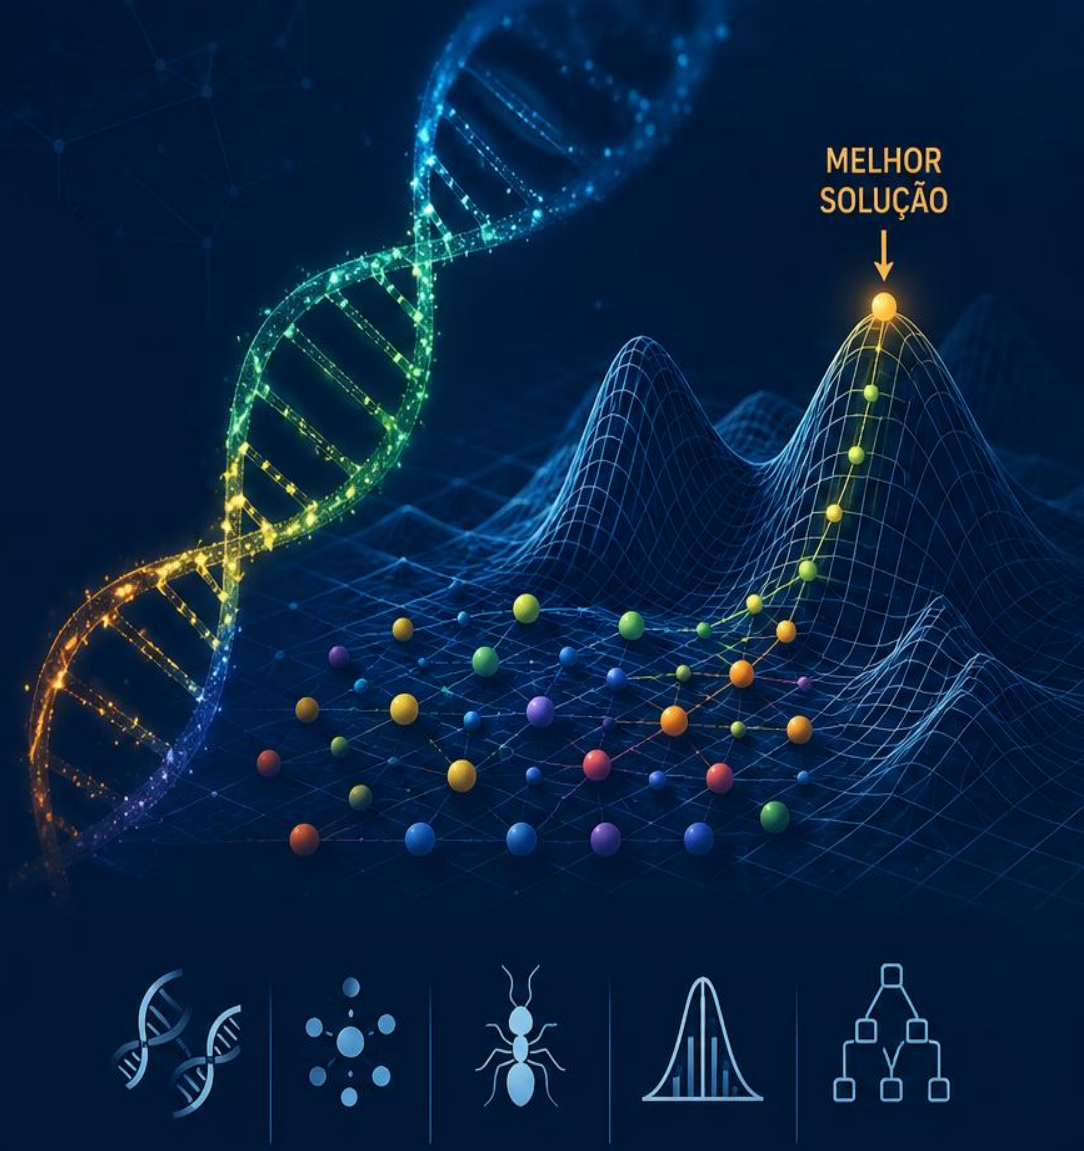
Differential Evolution



Introdução

- A **Evolução Diferencial (*Differential Evolution – DE*)** é um algoritmo de busca global estocástico, de fácil implementação e reconhecida eficiência.
- Proposto por **Storn e Price (1995).**
- Embora a Evolução Diferencial seja usualmente classificado como um algoritmo evolucionário, ele trabalha com uma população de soluções, mas **não é bioinspirado.**
- Uma população de soluções evolui com base em uma **estratégia matemática**, não havendo inspiração no processo de evolução das espécies.

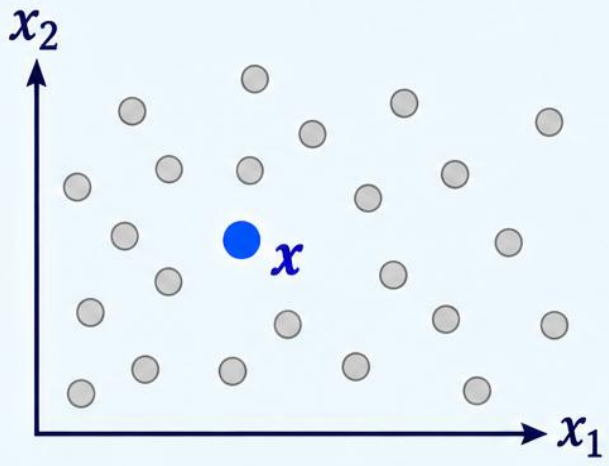
O DE é um método estocástico e populacional, voltado para problemas de otimização contínua.

GA X Differential Evolution

1. GA para problemas contínuos

Solução (indivíduo) no GA:

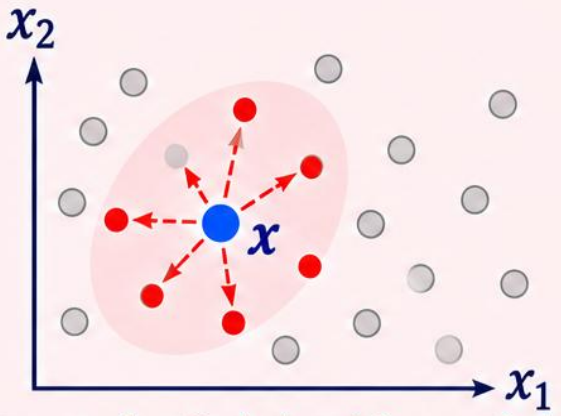
$$\boldsymbol{x} = [x_1, x_2, \ldots, x_D]$$



2. Mutação gaussiana no GA

Perturbamos cada componente:

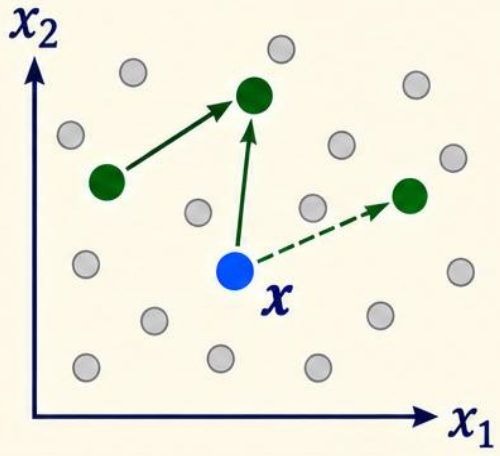
$$x'_j = x_j + \mathcal{N}(0, \sigma^2)$$



A perturbação é aleatória, seguindo uma distribuição (ex.: Gaussiana).

3. Uma nova ideia

Mas será que precisamos definir uma **distribuição de mutação**, como a Gaussiana?



E se a própria população pudesse nos dizer quanto e em qual direção devemos perturbar uma solução?

O que é Differential Evolution?

Differential Evolution (DE) é um algoritmo evolucionário populacional voltado principalmente à otimização contínua e não linear.
Ele trabalha com população, mutação, crossover e seleção e não necessita de derivadas.

População na geração g:

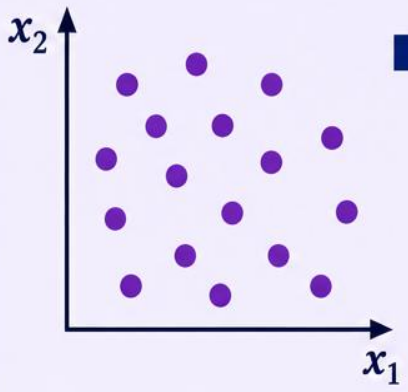
$$P^{(g)} = \left\{ x_1^{(g)}, x_2^{(g)}, \ldots, x_{NP}^{(g)} \right\}$$

x_1 x_2 $\cdots$ x_{NP}

NP indivíduos (vetores reais)

1 Inicialização

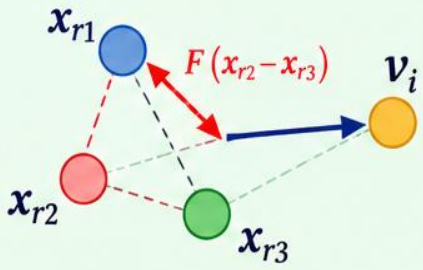
Gera uma população inicial de vetores reais no espaço de busca.



2 Mutação

Gera um vetor doador usando diferenças entre indivíduos da própria população.

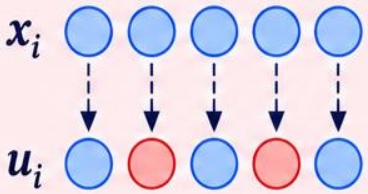
$$v_i^{(g)} = x_{r1}^{(g)} + F\left(x_{r2}^{(g)} - x_{r3}^{(g)}\right)$$



3 Crossover

Combina o vetor doador com o indivíduo alvo, gerando um vetor de teste.

$$u_i^{(g)} = \text{crossover}\left(x_i^{(g)}, v_i^{(g)}\right)$$



4 Seleção

Avalia e decide se o vetor de teste substitui o indivíduo alvo.

$$x_i^{(g+1)} = \begin{cases} u_i^{(g)}, & \text{se } f(u_i^{(g)}) \le f(x_i^{(g)}) \\ x_i^{(g)}, & \text{caso contrário} \end{cases}$$

$$f(u_i) \le f(x_i)$$

$$x_i^{(g+1)} = u_i$$

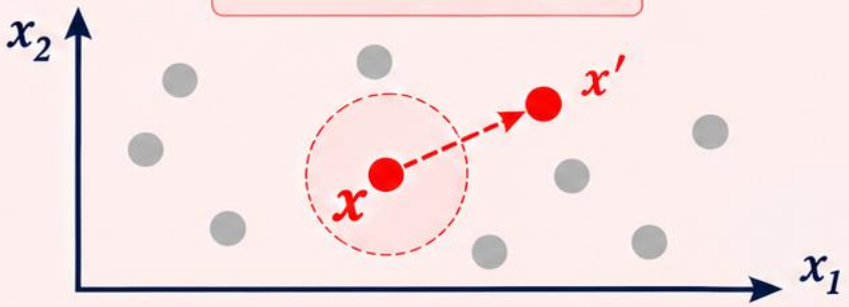
GA × DE: o que muda?

Aspecto	GA (real)	DE
Representação	Real	Real
População	Sim	Sim
Crossover	Sim (ex.: aritmético)	Sim (binomial ou exponencial)
Perturbação	Mutação aleatória	Diferenças da população
Parâmetro importante	p_m, σ, p_c	F, CR
Sobrevivência	Várias estratégias	***Target* × *trial***
Derivadas	Não	Não

GA: mutação aleatória

Cada variável é perturbada por um ruído aleatório para gerar uma nova solução.

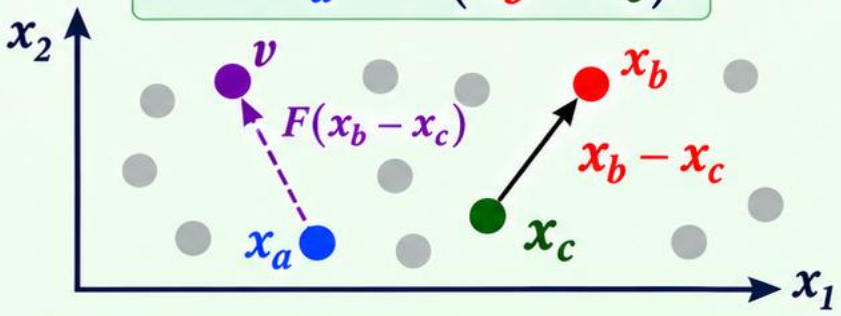
$$x' = x + \varepsilon$$



DE: mutação diferencial

A perturbação é construída a partir de diferenças entre vetores da própria população.

$$v = x_a + F(x_b - x_c)$$



A grande diferença está em como novos candidatos são gerados.

Representação e inicialização

Representação de um indivíduo

$$x_i = (x_{i,1}, \ldots, x_{i,D})$$

Cada indivíduo é um vetor de D variáveis reais.

Inicialização (distribuição uniforme)

$$x_{i,j} \sim U(L_j, U_j)$$

NP: tamanho da população
D: dimensão do problema
L_j, U_j: limites da variável j

População inicial

Matriz $NP \times D$ (cada linha é um indivíduo)

$$P^{(0)} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \cdots \\ x_{NP} \end{bmatrix} \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,D} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,D} \\ x_{3,1} & x_{3,2} & \cdots & x_{3,D} \\ \cdots & \cdots & \cdots & \cdots \\ x_{NP,1} & x_{NP,2} & \cdots & x_{NP,D} \end{bmatrix}$$

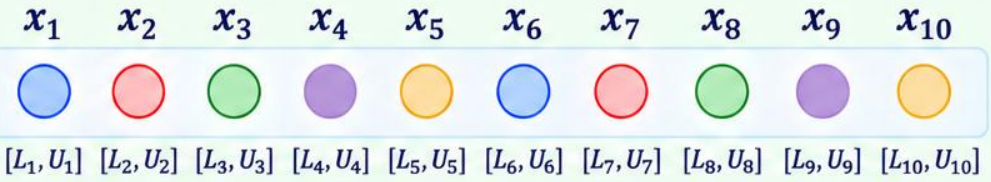
NP indivíduos (soluções candidatas)

D variáveis

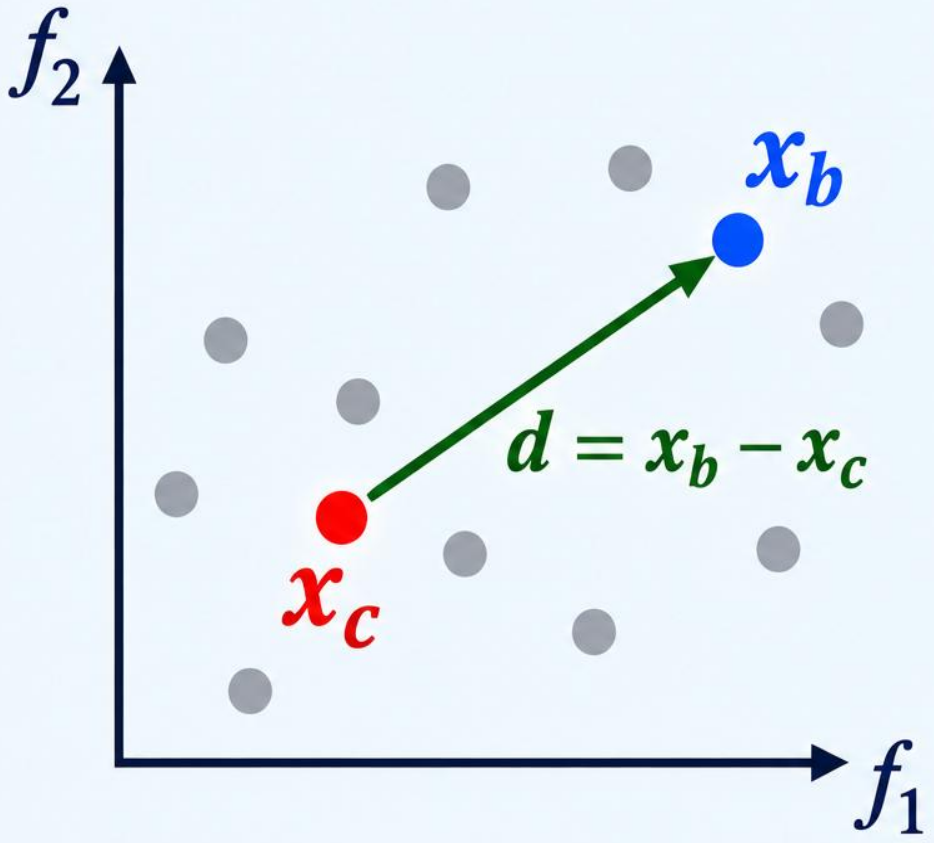
Exemplo: Rastrigin com $D = 10$

$$x_i = [x_1, x_2, \ldots, x_{10}]$$

Cada indivíduo é uma solução candidata no espaço de 10 dimensões.



A ideia fundamental: diferença entre vetores



Considere dois indivíduos:

x_b e x_c

Calcule:

$$d = x_b - x_c$$

O vetor d possui:

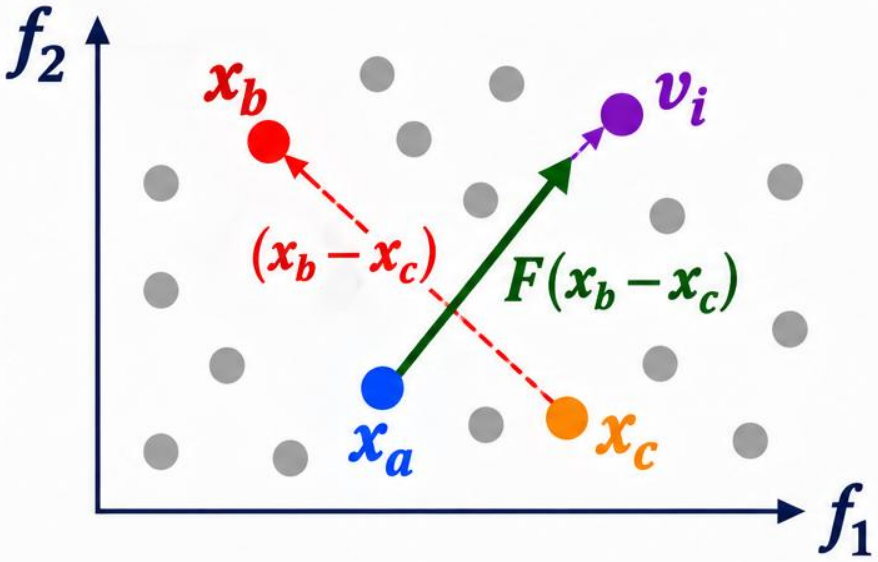
→	**Direção**	indica a orientação entre as duas soluções.
→	**Sentido**	de x_c para x_b.
↔	**Magnitude**	é a distância entre as duas soluções.

A diferença entre duas soluções fornece informação sobre a geometria atual da população.

Mutação diferencial: DE/rand/1

$$v_i = x_a + F(x_b - x_c)$$

a, b, c são distintos entre si e do indivíduo-alvo i, e F é o fator de escala.



x_a	**Vetor base** Indivíduo escolhido aleatoriamente.
x_b, x_c	**Vetores para a diferença** Indivíduos distintos de a, b, c e i.
F	**Fator de escala** Controla o tamanho da perturbação. (tipicamente $0 < F \leq 1$)
v_i	**Vetor mutante** Novo candidato gerado pela mutação.

A mutação diferencial cria um novo vetor a partir da diferença entre dois indivíduos da população.

Exemplo numérico da mutação

1. Indivíduos e parâmetro

$$x_a = (2, 3) \qquad x_b = (5, 4)$$
$$x_c = (3, 1) \qquad F = 0.5$$

2. Diferença entre vetores

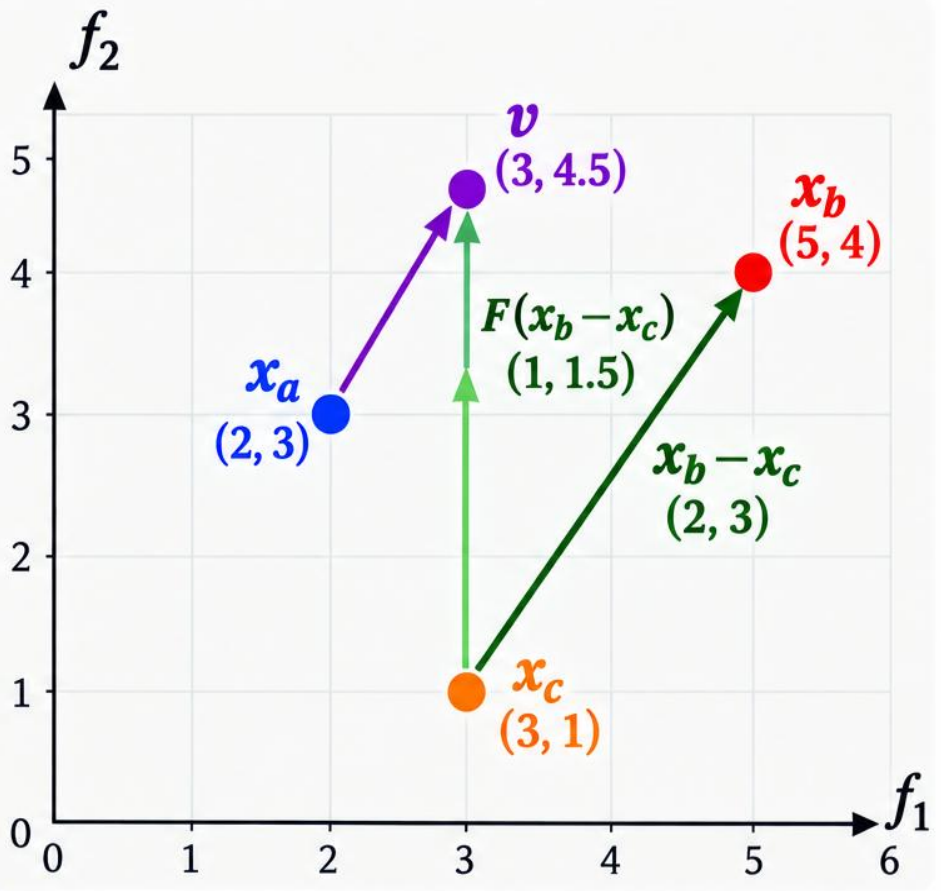
$$x_b - x_c = (5, 4) - (3, 1)$$
$$x_b - x_c = (2, 3)$$

3. Escala da diferença

$$F(x_b - x_c) = 0.5 \cdot (2, 3)$$
$$F(x_b - x_c) = (1, 1.5)$$

4. Soma ao vetor base

$$v = x_a + F(x_b - x_c) = (2, 3) + (1, 1.5)$$
$$v = (3, 4.5)$$



O vetor mutante é gerado a partir de um vetor da população somado a uma diferença entre dois outros vetores.

O papel do fator F

$$v = x_a + F(x_b - x_c)$$

O fator F escala o vetor diferença

$x_b - x_c$,

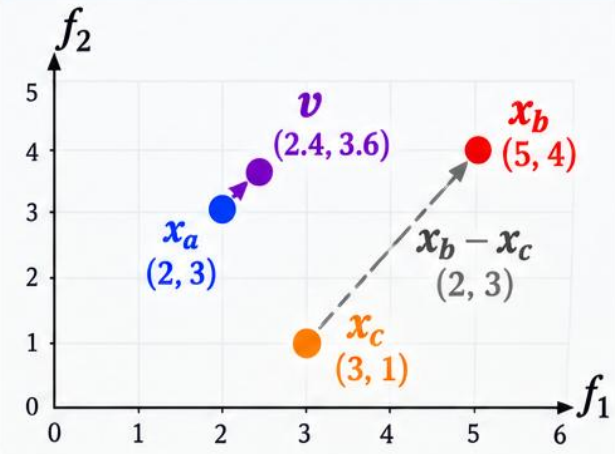
definindo o tamanho do deslocamento.

Valores típicos

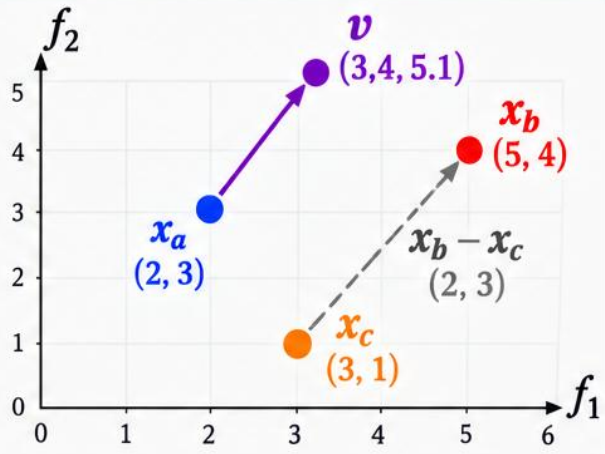
$$0.4 \leq F \leq 1.0$$

(podem variar conforme o problema)

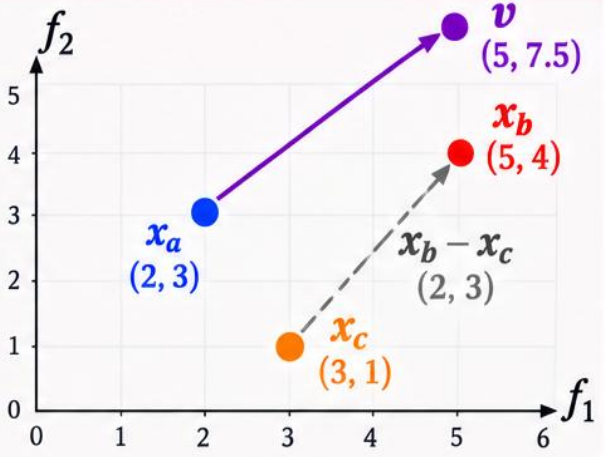
$F = 0.2$ (deslocamento pequeno)



$F = 0.7$ (deslocamento intermediário)



$F = 1.5$ (deslocamento grande)



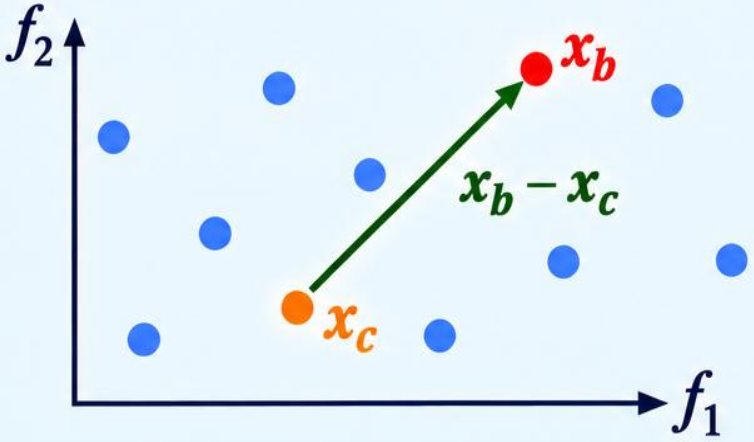
$F \uparrow \Rightarrow$ **passos potencialmente maiores.**

$F \downarrow \Rightarrow$ **passos menores.**

Uma propriedade muito interessante do DE

População muito espalhada

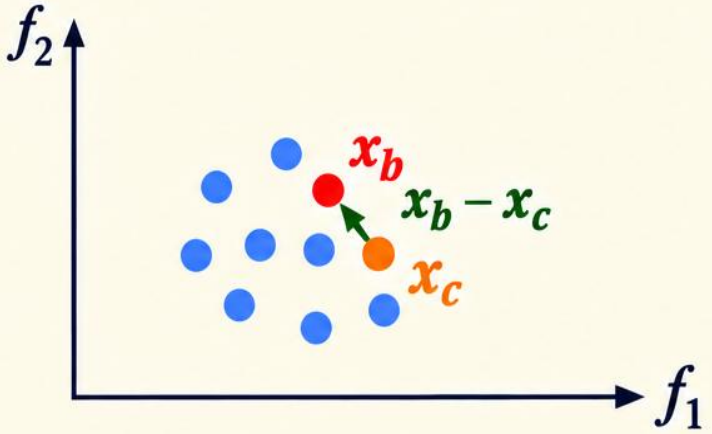
$\|x_b - x_c\|$ tende a ser maior.



Passos diferenciais podem ser maiores.

População começando a convergir

$\|x_b - x_c\| \to 0.$



Perturbações tendem a diminuir.

Mutação gaussiana (GA)

$$x' = x + \mathcal{N}(0, \sigma^2)$$

Precisamos definir o desvio padrão σ.

$\Rightarrow$

O tamanho da perturbação se adapta, em parte, à própria distribuição da população.

Target, mutant e trial

Target vector

$$x_i$$

Indivíduo que estamos tentando substituir (indivíduo-alvo).

$$x_i = \begin{bmatrix} x_{i,1} \\ x_{i,2} \\ \vdots \\ x_{i,D} \end{bmatrix}$$

Mutant vector

$$v_i = x_a + F(x_b - x_c)$$

Gerado pela mutação diferencial.

$$v_i = \begin{bmatrix} v_{i,1} \\ v_{i,2} \\ \vdots \\ v_{i,D} \end{bmatrix}$$

Trial vector

$$u_i$$

Resultado do crossover entre target e mutant.

$$u_i = \begin{bmatrix} u_{i,1} \\ u_{i,2} \\ \vdots \\ u_{i,D} \end{bmatrix}$$

x_i **target vector** (indivíduo-alvo) + v_i **mutant vector** (mutação diferencial) **crossover** → u_i **trial vector** (após o crossover)

Crossover binomial

$$u_{i,j} = \begin{cases} v_{i,j}, & r_j \leq CR \quad \text{ou} \quad j = j_{rand} \\ x_{i,j}, & \text{caso contrário.} \end{cases}$$

Exemplo $(D = 6,\ CR = 0.5)$

j	1	2	3	4	5	6
r_j $(0-1)$	0.32	0.80	0.12	0.65	0.41	0.73
Condição	$\leq CR$	$> CR$	$\leq CR$	$> CR$	$\leq CR$	$> CR$
x_i (target)	1.0	2.0	3.0	4.0	5.0	6.0
v_i (mutant)	8.0	9.0	10.0	11.0	12.0	13.0
u_i (trial)	8.0	2.0	10.0	4.0	12.0	6.0

Copiou do mutant $(r_1 \leq CR)$

Copiou do mutant $(r_3 \leq CR)$

Copiou do mutant $(r_5 \leq CR)$

$CR \in [0,1]$

Probabilidade de copiar cada componente do vetor mutante.

j_{rand}

Índice aleatório para garantir que pelo menos uma componente venha do vetor mutante.

Para cada variável, decidimos se copiamos o valor do *target* ou do *mutant*.

Exemplo visual do crossover

Vetor alvo (target)

$$x_i = [\ 2.0 \quad 4.0 \quad 1.0 \quad 7.0 \quad 3.0\ ]$$

Vetor mutante (mutant)

$$v_i = [\ 2.7 \quad 3.1 \quad 4.2 \quad 6.5 \quad 1.8\ ]$$

Após o crossover, cada componente vem do target ou do *mutant*.

$u_{i,j} = v_{i,j}$ Componente copiada do ***mutant***

$u_{i,j} = x_{i,j}$ Componente copiada do ***target***

$j =$	1	2	3	4	5
x_i (target)	2.0	4.0	1.0	7.0	3.0
v_i (mutant)	2.7	3.1	4.2	6.5	1.8
Escolha	do mutant	do target	do mutant	do target	do mutant
u_i (trial)	2.7	4.0	4.2	7.0	1.8

$$u_i = [\ 2.7 \quad 4.0 \quad 4.2 \quad 7.0 \quad 1.8\ ]$$

Por que existe j_{rand} ?

Exemplo: suponha $CR = 0.1$

Para cada posição j, sorteamos $r_j \in [0,1]$ e copiamos do **mutante** se $r_j \leq CR$.

Com $CR = 0.1$, é possível que ***nenhuma*** posição seja escolhida do mutante. $\Rightarrow u_i = x_i$

Sem j_{rand}

$j =$	1	2	3	4	5
r_j	0.32	0.45	0.28	0.91	0.63
$r_j \leq CR$?	Não	Não	Não	Não	Não
u_i (trial)	2.0	4.0	1.0	7.0	3.0

Nenhuma componente foi copiada do mutante.

$\Rightarrow u_i = x_i$

Não criamos uma nova solução.

Com j_{rand}

$j =$	1	2	3	4	5
r_j	0.32	0.45	0.28	0.91	0.63
$r_j \leq CR$?	Não	Não	Não	Não	Não
$j_{rand} = 3$	–	–	✓	–	–
u_i (trial)	2.0	4.0	4.2	7.0	3.0

Garantimos que pelo menos uma posição venha do mutante:

$u_{i,j_{rand}} = v_{i,j_{rand}}$.

No exemplo, a posição 3 foi copiada do mutante.

➡ **O *trial* deve diferir do *target* em pelo menos uma variável.**

Seleção: target × trial

$$x_i^{(g+1)} = \begin{cases} u_i, & f(u_i) \leq f(x_i) \\ x_i, & \text{caso contrário.} \end{cases}$$

x_i versus u_i

Target

x_i

$f(x_i)$

→ Compara os valores da função objetivo →

Trial

u_i

$f(u_i)$

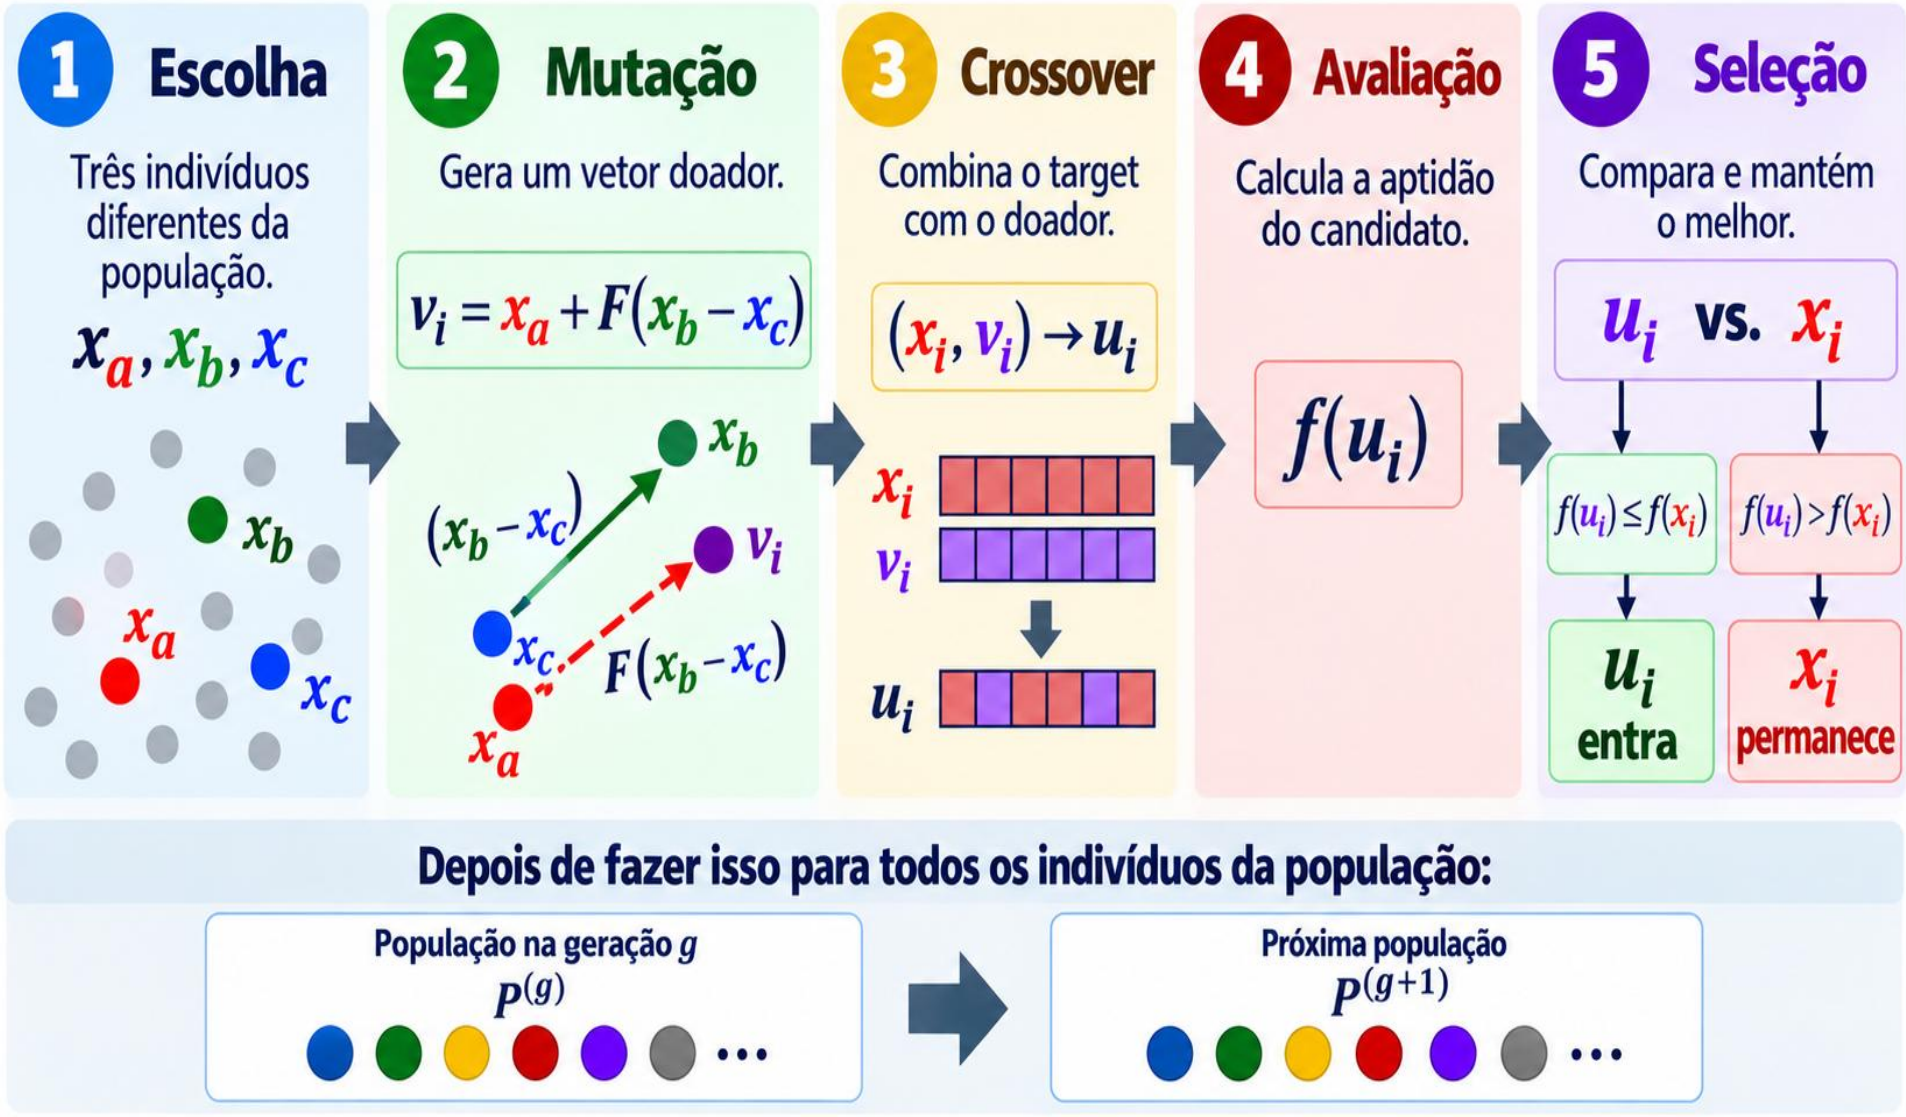
Se $f(u_i) \leq f(x_i)$ ⇒ u_i sobrevive

Se $f(u_i) > f(x_i)$ ⇒ x_i sobrevive

Não estamos procurando globalmente "quem é o pior indivíduo da população".

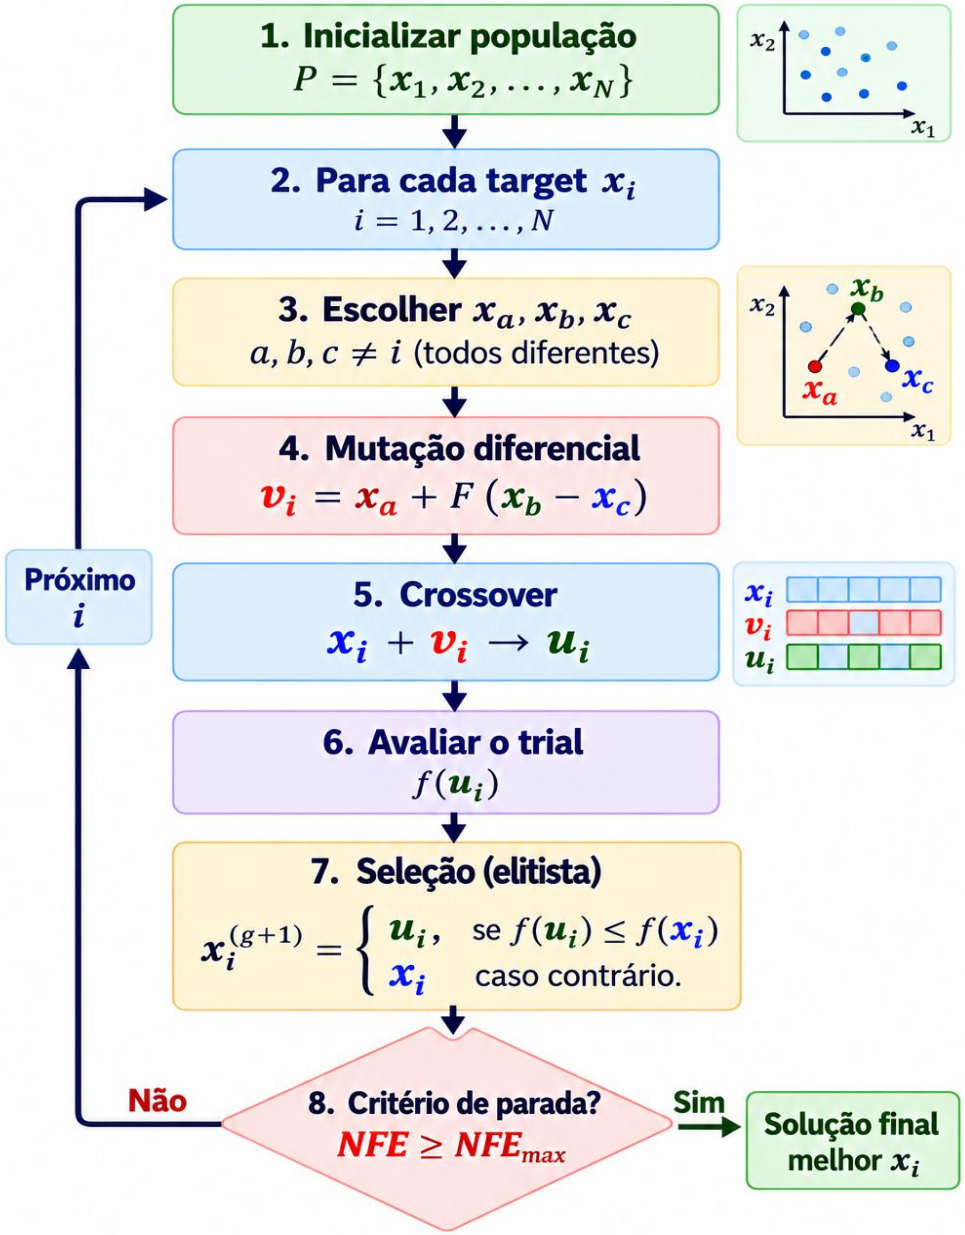
Cada *trial* compete diretamente com seu *target*.

Uma geração completa



Depois de fazer isso para todos os indivíduos da população:

Fluxograma do DE



Critério de parada: novamente NFE

NFE = Number of Function Evaluations

Número total de avaliações da função objetivo $f(x)$.

Avaliações no DE

$f(u_i)$ → Cada trial precisa ser avaliado. Isso custa 1 avaliação da FO.

Uma geração (população de N indivíduos)

u_1 → $f(u_1)$; u_2 → $f(u_2)$; ... ; u_N → $f(u_N)$

N novas avaliações

→ Após G gerações: $NFE = G \times N$

Comparação justa entre algoritmos

GA × DE →

Usar o **mesmo orçamento de NFE** para comparar o desempenho.

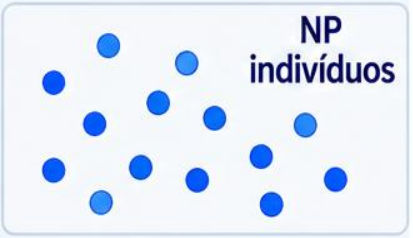
Os três parâmetros principais

NP
Tamanho da população

Número de indivíduos na população.

$$P = \{x_1, x_2, \ldots, x_{NP}\}$$

Faixa típica
5D a 10D
(D = dimensão do problema)

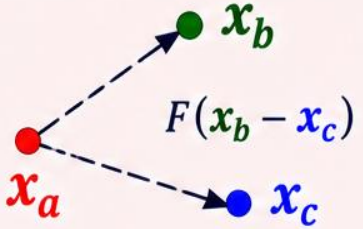


F
Fator de escala da diferença

Controla o tamanho do passo na mutação diferencial.

$$v_i = x_a + F\,(x_b - x_c)$$

Faixa típica
0.4 a 1.0

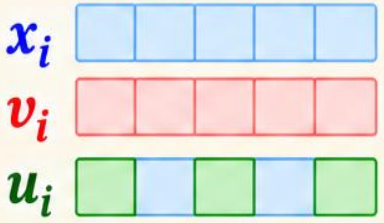


CR
Taxa de crossover

Probabilidade de copiar cada componente do mutante.

$$u_{i,j} = \begin{cases} v_{i,j}, & \text{se } r_j \le CR \text{ ou } j = j_{\text{rand}} \\ x_{i,j}, & \text{caso contrário.} \end{cases}$$

Faixa típica
0.5 a 0.9



NFE_{max}
Orçamento computacional

Número máximo de avaliações da função objetivo.

NFE = Number of Function Evaluations

Definido pelo usuário
NFE_{max}

Cada trial precisa ser avaliado:
$f(u_i)$
Isso custa 1 avaliação da FO.

DE/rand/1: o que significa o nome?

DE / rand / 1 / bin

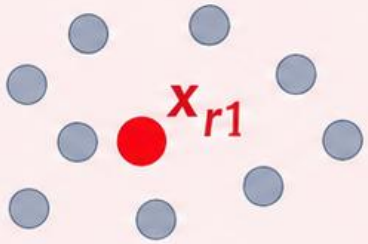
DE

Differential Evolution

Algoritmo de otimização populacional.

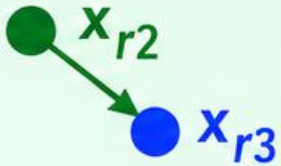
rand

Vetor base escolhido aleatoriamente na população.



1

Uma diferença entre dois vetores da população.



$(x_{r2} - x_{r3})$

bin

Crossover binomial.

Cada componente do vetor candidato é escolhido, com probabilidade *CR*, entre o doador e o *target*.

Vetor doador da estratégia DE/rand/1/bin:

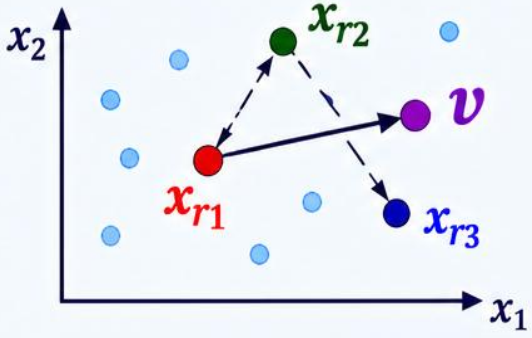
$$v = x_{r1} + F(x_{r2} - x_{r3}).$$

Estratégias de mutação

DE/rand/1

$$v = x_{r1} + F\,(x_{r2} - x_{r3})$$

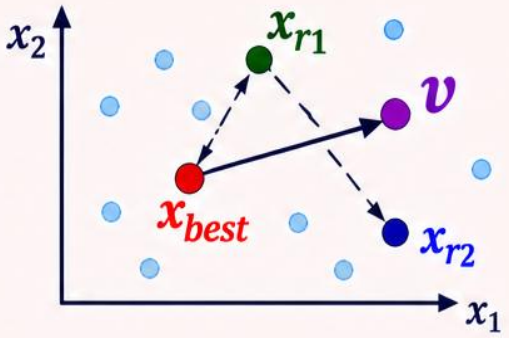
Maior tendência exploratória.



DE/best/1

$$v = x_{best} + F\,(x_{r1} - x_{r2})$$

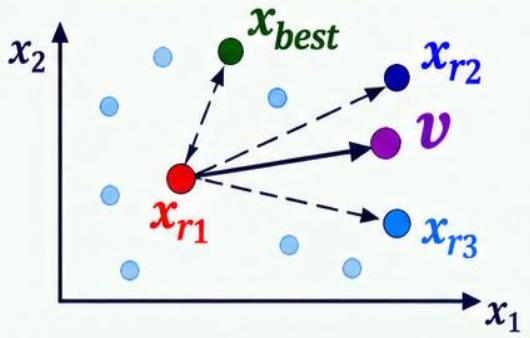
Mais direcionado ao melhor.



DE/rand-to-best/1

$$v = x_{r1} + F\,(x_{best} - x_{r1}) + F\,(x_{r2} - x_{r3})$$

Combina exploração e direção ao melhor.



DE/rand/2

$$v = x_{r1} + F\,(x_{r2} - x_{r3}) + F\,(x_{r4} - x_{r5})$$

Duas diferenças. Mais exploratória.

DE/best/2

$$v = x_{best} + F\,(x_{r1} - x_{r2}) + F\,(x_{r3} - x_{r4})$$

Duas diferenças. Mais direcionado ao melhor.

➡ **Existe uma família de estratégias.** Na disciplina, focaremos em **DE/rand/1**.

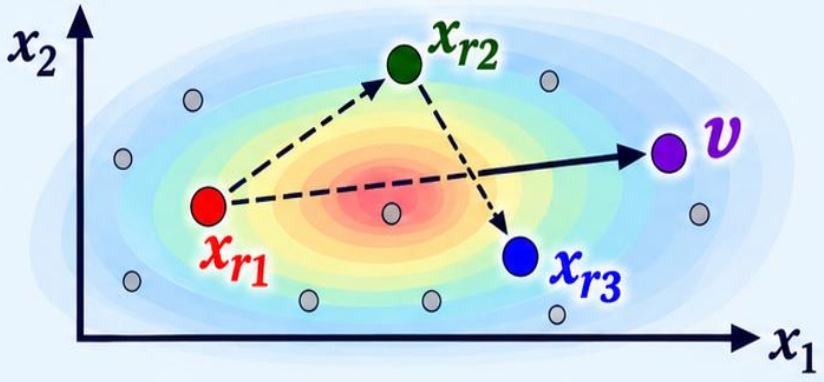
Exploration × exploitation no DE

DE/rand/1

$$v = x_{r1} + F\,(x_{r2} - x_{r3})$$

Mais exploratório

Movimentos baseados em indivíduos aleatórios da população.

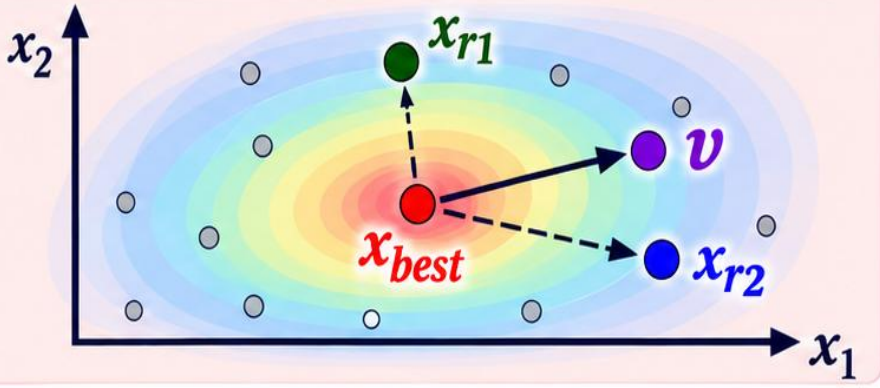


DE/best/1

$$v = x_{best} + F\,(x_{r1} - x_{r2})$$

Mais direcionado ao melhor

Exploração da vizinhança da melhor solução atual.



O equilíbrio é influenciado por:

- **F** — tamanho do passo (movimentos maiores ou menores)
- **CR** — probabilidade de copiar do mutante
- **Estratégia de mutação** — rand/1, best/1, rand-to-best/1, …
- **Diversidade da população** — maior diversidade → mais exploração; menor diversidade → mais exploração

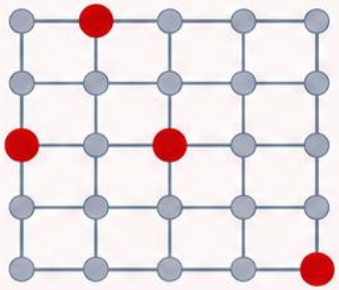
Quando o DE não é a 1ª escolha

Variáveis inteiras ou discretas

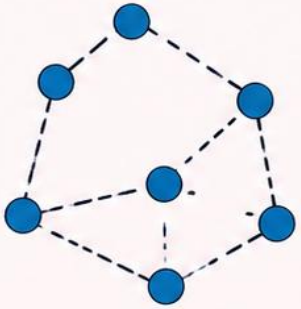
$x \in \mathbb{Z}^n$

ou

$x \in \{0,1\}^n$

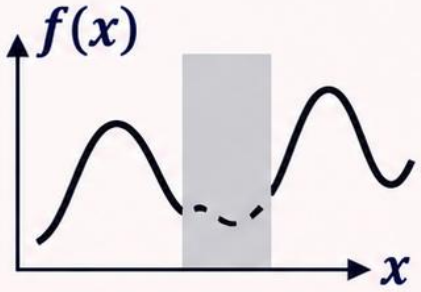


Problemas puramente combinatórios



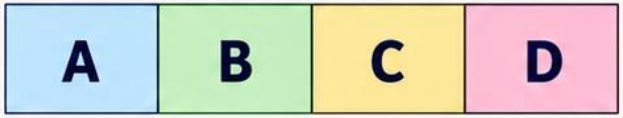
TSP, roteamento, escalonamento, alocação, ...

Funções não definidas ou muito caras



Função não definida em parte do domínio

Variáveis categóricas (nominais)



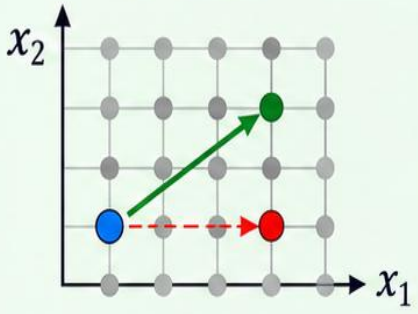
Não há sentido em usar diferenças entre categorias.

O DE clássico foi projetada para otimização contínua e costuma não ser a 1ª escolha para problemas discretos ou combinatórios.

Extensões do Differential Evolution

Integer DE
(para variáveis inteiras)

$$x \in \mathbb{Z}^n$$



- Adapta operadores para manter soluções inteiras.
- Usa arredondamento ou mecanismos específicos.

Binary DE
(para variáveis binárias)

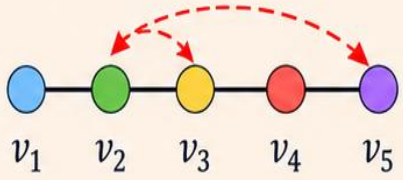
$$x \in \{0,1\}^n$$



- Utiliza uma versão binária da mutação diferencial.
- Converte os valores reais em probabilidades (e.g., função sigmoide) para gerar 0 ou 1.

Discrete DE
(para variáveis discretas)

$$x_j \in \{v_1, v_2, \ldots, v_k\}$$

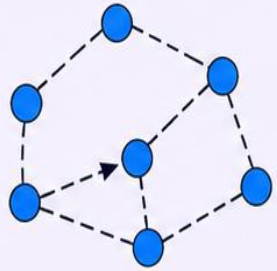


- Define um conjunto finito de valores para cada variável.
- Após mutação e cruzamento, o valor é mapeado para o valor discreto mais próximo ou selecionado por uma regra probabilística.

DE para problemas combinatórios

$$x \in S$$

(conjunto de soluções combinatórias)



- Adapta a ideia de mutação diferencial usando representações específicas (p.ex.: permutação, sequência, subconjuntos).
- Utiliza operadores próprios de vizinhança (troca, inserção, inversão, etc.).

A formulação clássica do DE foi projetada para otimização contínua e costuma não ser a primeira escolha para problemas discretos ou combinatórios, embora existam diversas extensões que tornam o DE aplicável a essas áreas.